BWA-GATK Pipeline za obradu egzomskih FASTQ podataka i analizu varijanti

Pipeline je implementiran u Python-u i obuhvata sledeće korake:

- FastQC kontrolu kvaliteta,
- mapiranje readova pomoću BWA-MEM algoritma,
- sortiranje i indeksiranje BAM fajlova,
- markiranje duplikata,
- Base Quality Score Recalibration (BQSR),
- identifikaciju varijanti pomoću GATK HaplotypeCaller alata,
- hard filtering varijanti.

1. Ulazni podaci

U projektu su korišćeni **paired-end FASTQ fajlovi** dobijeni egzomskim sekvenciranjem dela hromozoma 11 iz *1000 Genomes* projekta. Ulazni fajlovi su:

- `sample_0.chrom11.exome.pe1.fq.gz`
- `sample_0.chrom11.exome.pe2.fq.gz`

Kao referentni genom korišćen je **hg38** (`Homo_sapiens_assembly38.fasta`), dok je **dbSNP** baza korišćena kao skup poznatih varijanti tokom BQSR koraka (`Homo_sapiens_assembly38.dbsnp138.vcf.gz`)

2. Pokretanje pipeline-a

```
python run_pipeline.py \
  --fastq1 data/sample_0.chrom11.exome.pe1.fq.gz \
  --fastq2 data/sample_0.chrom11.exome.pe2.fq.gz \
  --reference data/reference/Homo_sapiens_assembly38.fasta \
  --known-sites data/known_sites/Homo_sapiens_assembly38.dbsnp138.vcf.gz \
  --output-dir results/
```

3. Rezultati mapiranja (BWA-MEM)

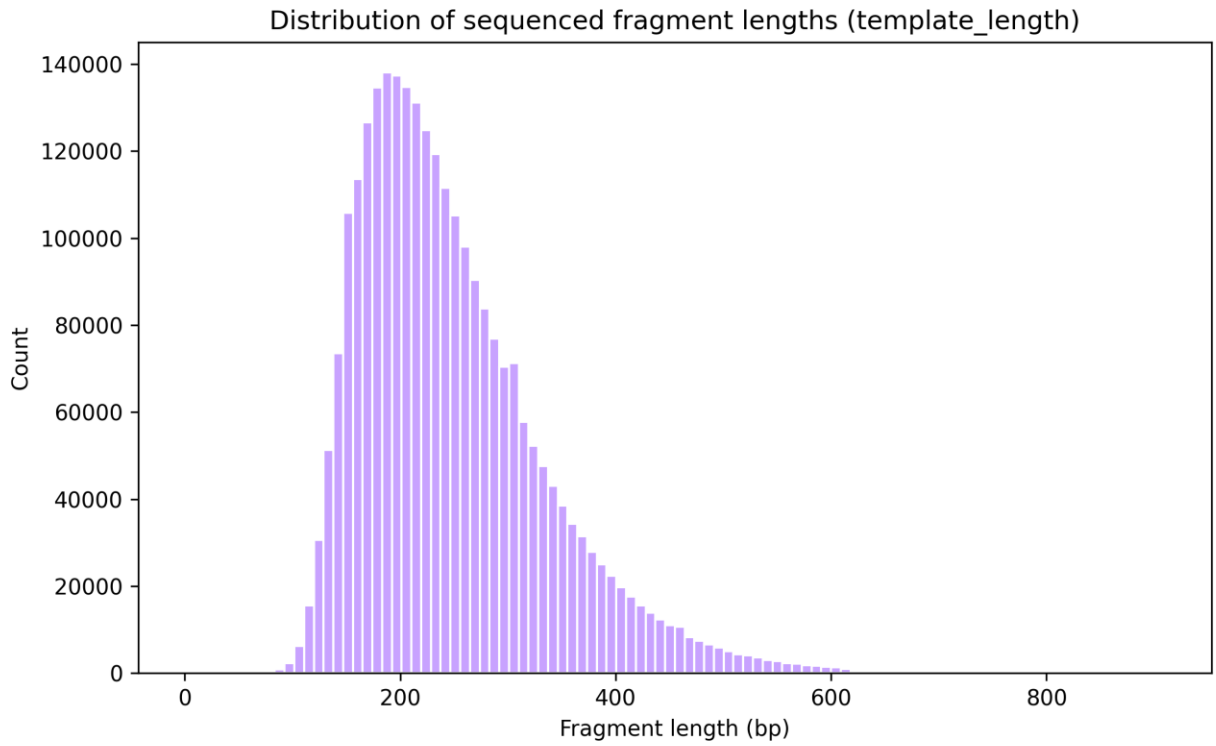
Ukupan broj readova:	6,065,505
Mapirani readovi:	5,476,332 (90.29%)
Properly paired:	5,396,810 (89.05%)
Procenat PCR duplikata:	3.48%

Visok procenat mapiranih readova (90.29%) ukazuje na dobro poklapanje uzorka sa referentnim genomom hg38.

Properly paired readovi predstavljaju paired-end read parove koji su uspešno mapirani na očekivanoj udaljenosti i orijentaciji na referentnom genomu.

Procenat duplikata od 3.48% je u očekivanom opsegu za exome sekvenciranje i ne ukazuje na probleme u pripremi uzorka.

4. Histogram dužina fragmenata

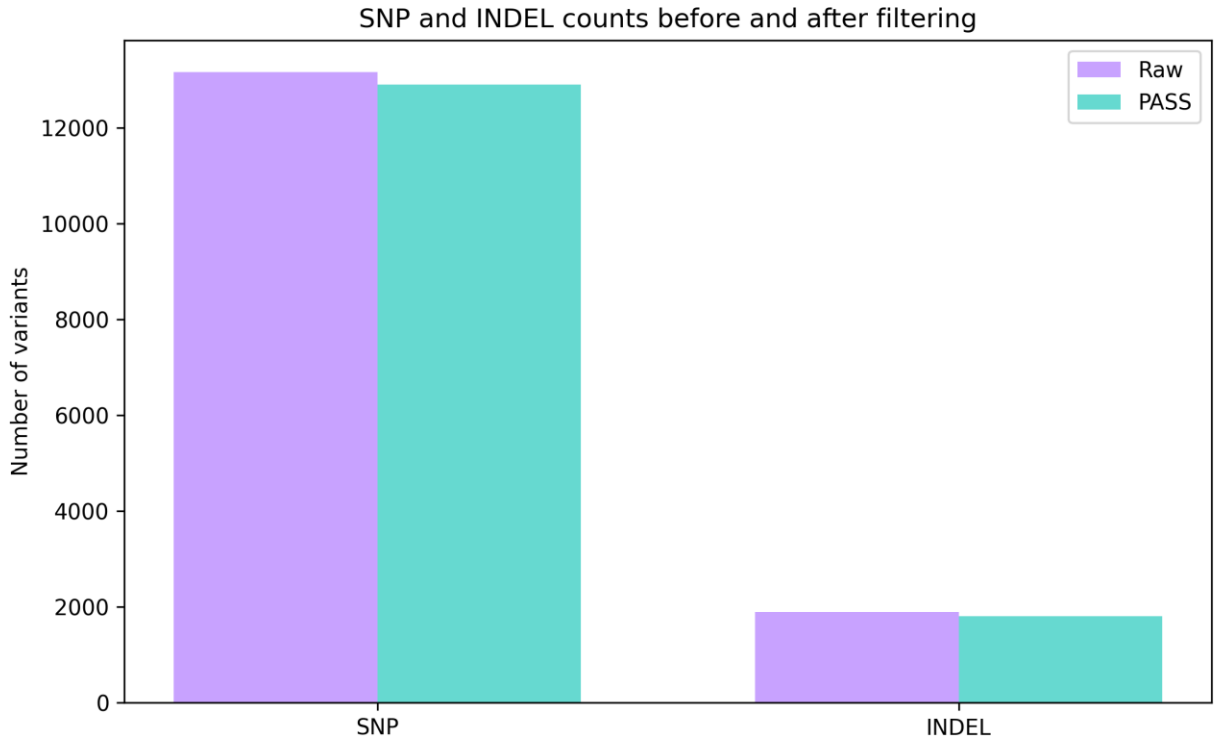


Histogram dužina sekvenciranih fragmenata pokazuje da najveći broj fragmenata ima dužinu približno između **150 i 300 baznih parova (bp)**, sa maksimumom oko 200 bp. Distribucija pokazuje očekivani oblik za paired-end egzomsko sekvenciranje.

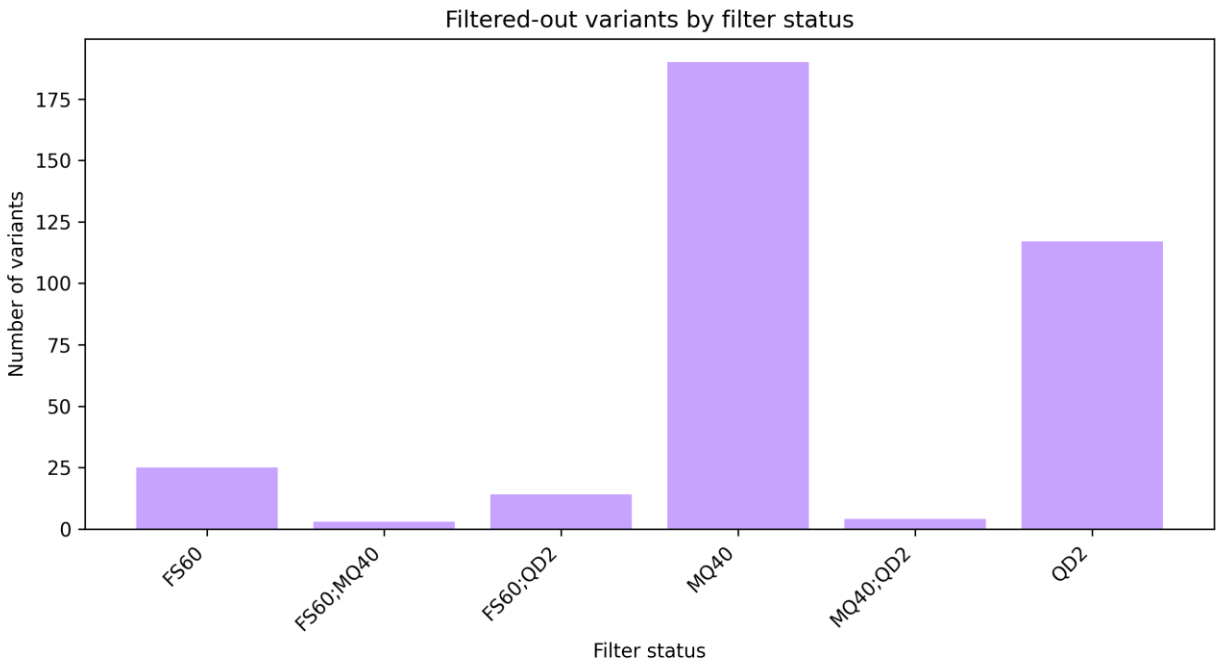
5. Analiza varijanti

	Pre filtriranja	Posle filtriranja (PASS)
Ukupno:	15,054	14,697
SNP	13,166	12,899
INDEL	1,892	1,798

Filtrirane varijante: 357 (2.37%)



Filter:	Broj varijanti
MQ40 (loš kvalitet mapiranja)	190
QD2 (Quality by Depth)	117
FS60 (strand bias)	25
FS60;QD2	14
MQ40;QD2	4
FS60;MQ40	3



Hard filtering je označio 357 varijanti kao nepouzdane, što čini samo 2.37% ukupnog skupa. Ovo ukazuje na visok kvalitet ulaznih podataka i uspešnu rekalibraciju.

Najveći broj odbačenih varijanti nije prošao MQ40 i QD2 filtere, što ukazuje na probleme sa kvalitetom mapiranja na referentni genom i odnosom kvaliteta prema dubini pokrivenosti.

Broj SNP varijanti ostao je znatno veći od broja INDEL varijanti i pre i posle filtriranja. Posmatrajući filtriranje po tipu varijante, SNP-ovi su odbijeni u manjem procentu (2.03%) u odnosu na INDEL-e (4.97%). Ovo je očekivano — INDEL-i su strukturno složeniji od SNP-ova i teži za precizno sekvenciranje i mapiranje, pa češće ne prolaze filtere kvaliteta.